

# Bootcamp Machine Learning



## SEGMENTAÇÃO PULMONAR

### Equipe 05:

Edson Moku Yabiku  
Erick Vieira Maestrello  
Henri Silva de Oliveira Reis  
Jonathas Magalhães  
José Lisiomar de Souza  
Robson Amorim de Melo  
Vinícius Arantes Emrich Leão



## ■ **Objetivo:**

Este estudo visa aplicar técnicas de aprendizado de máquina para segmentar imagens de pulmão de forma precisa e eficiente, visando auxiliar profissionais da saúde no diagnóstico e tratamento de doenças respiratórias.

## ■ **Metodologia:**

Utilizaremos a técnica de segmentação de imagens com algoritmos de Machine Learning para identificar e demarcar as áreas das radiografias que apresentam anomalias.

Os algoritmos serão treinados com um conjunto de dados rotulados com as respectivas anomalias e aprenderão a identificar padrões nas imagens que indiquem a presença de irregularidades.





# Introdução:

As doenças pulmonares representam um problema de saúde pública global e o diagnóstico precoce das doenças respiratórias é crucial para um tratamento eficaz e a redução da mortalidade, no entanto, a análise manual de radiografias pode ser complexa, demorada e suscetível a erros humanos.

Ao contrário da análise manual de radiografias, a técnica de segmentação de imagens automatizada garante maior precisão na identificação de anomalias, permitindo análises rápidas e eficientes em um grande número de exames radiográficos. Isso significa que os pacientes poderão receber um diagnóstico mais rápido e iniciar o tratamento com mais agilidade, aumentando as chances de sucesso.



# Utilização de (ML) em Imagens Médicas

O Machine Learning está revolucionando o campo da medicina no diagnóstico, tratamento e acompanhamento de doenças. As imagens médicas, como radiografias, tomografias e ressonâncias magnéticas, se tornaram um terreno fértil para a aplicação dessa tecnologia inovadora, oferecendo resultados promissores que transformam a vida de pacientes e profissionais da saúde.

■ Alguns exemplos da utilização dessa técnica na área médica são:

1. Auxílio na Segmentação de Tumores em Ressonâncias Magnéticas;
2. Análise Preditiva de Risco de Doenças Cardíacas;
3. Detecção e Classificação de Células Cancerígenas em imagens de biópsia, entre outros.



# Desafios na Segmentação de Imagens Pulmonares

## ■ Variabilidade Anatômica

As estruturas pulmonares apresentam uma ampla diversidade anatômica entre indivíduos, o que dificulta a criação de modelos de segmentação genéricos.

## ■ Sobreposição de Tecidos

A proximidade e a semelhança entre os tecidos pulmonares e outras estruturas torácicas desafiam a segmentação precisa.

## ■ Qualidade da Imagem

Fatores como ruído, artefatos e baixo contraste podem prejudicar a precisão dos algoritmos de segmentação.

## ■ Doenças Pulmonares

Condições como nódulos, lesões e consolidações podem alterar a aparência das estruturas pulmonares, dificultando a segmentação.


# Pré-processamento de Imagens Pulmonares



O pré-processamento de imagens pulmonares é uma etapa crucial na análise de imagens médicas, especialmente em tomografias computadorizadas do pulmão

- **Segmentação:** A segmentação é uma técnica comum de pré-processamento usada para identificar e isolar regiões específicas de interesse, como os pulmões, em uma imagem. Por exemplo, um estudo propôs uma metodologia de segmentação por blocos em imagens de tomografia de pulmão usando extratores de características.
- **Extração de Características:** Após a segmentação, as características são extraídas das regiões de interesse para análise posterior.
- **Quantificação e Visualização da Aeração Pulmonar:** Além disso, as ferramentas de pré-processamento podem ser usadas para quantificar e visualizar a aeração pulmonar em imagens de tomografia computadorizada

Essas transformações preparam as imagens para modelos de aprendizado de máquina, melhorando a precisão e eficiência dos resultados.







# Técnicas de Aprendizado de Máquina para Segmentação Pulmonar

## Segmentação por Limiarização

Técnica simples e eficiente que utiliza limiares de intensidade para separar os tecidos pulmonares das estruturas circundantes.

1

2

## Segmentação por Crescimento de Regiões

Abordagem que agrupa pixels vizinhos com características semelhantes, permitindo a delimitação precisa dos contornos pulmonares.

## Redes Neurais Convolucionais

Arquiteturas avançadas de aprendizado profundo capazes de aprender as características relevantes das imagens e realizar a segmentação pulmonar de forma automatizada.

3

# Arquiteturas de Redes Neurais Convolucional

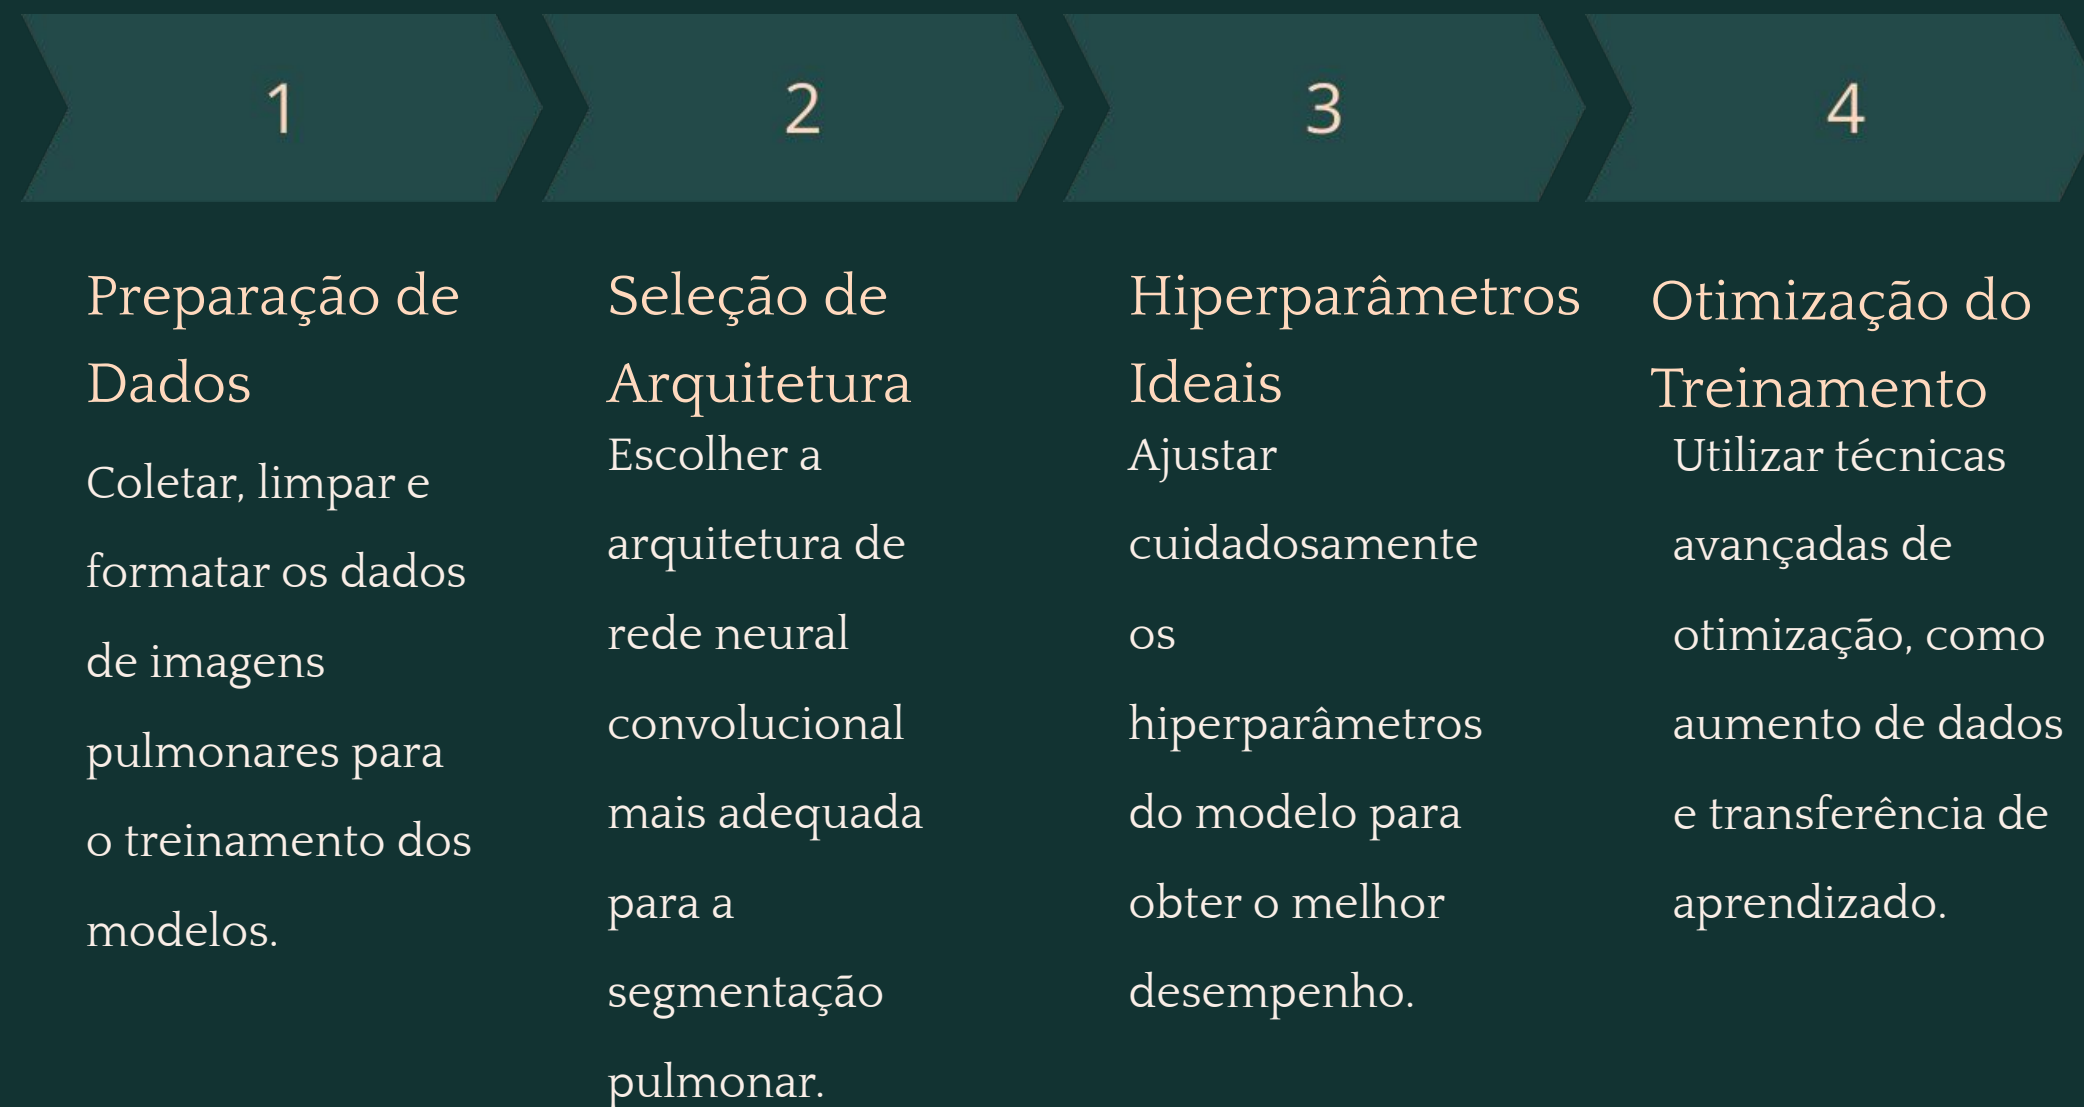
- **Camadas Convolucionais**  
As camadas convolucionais extraem recursos visuais relevantes das imagens, como texturas, formas e padrões.
- **Camadas de Agrupamento**  
As camadas de agrupamento reduzem a dimensionalidade das representações, mantendo as características mais importantes.
- **Camadas Totalmente Conectadas**  
As camadas totalmente conectadas realizam a classificação final com base nas características extraídas pelas camadas anteriores.
- **Funções de Ativação**  
As funções de ativação, como ReLU, adicionam não-linearidade à rede, permitindo a aprendizagem de características complexas.



# Bibliotecas Utilizadas

- **OpenCV:** A principal biblioteca utilizada para segmentação de imagem é a OpenCV (Open Source Computer Vision Library). Desenvolvida e lançada pela Intel em 1999, a OpenCV é uma biblioteca de código aberto que é frequentemente usada para tarefas de visão computacional, como detecção facial, detecção de objetos, reconhecimento facial e, claro, segmentação de imagens.
- **NumPy:** A biblioteca Numpy é fundamental para a segmentação de imagens, principalmente por sua capacidade de manipular arrays multidimensionais, principais pontos que consistem são; representação de imagens, manipulação de pixels, operações matemáticas, integração com outras bibliotecas, Numpy desempenha um papel crucial na segmentação de imagens.
- **Matplotlib:** A biblioteca Matplotlib é essencial para segmentação de imagens, principalmente por sua capacidade de visualizar dados, principais pontos; visualização de imagens, visualização de segmentos, visualização de histogramas e visualização de resultados, com sua capacidade de visualizar dados, desempenha um papel crucial na segmentação de imagens.

# Treinamento de Modelos de Aprendizado de Máquina



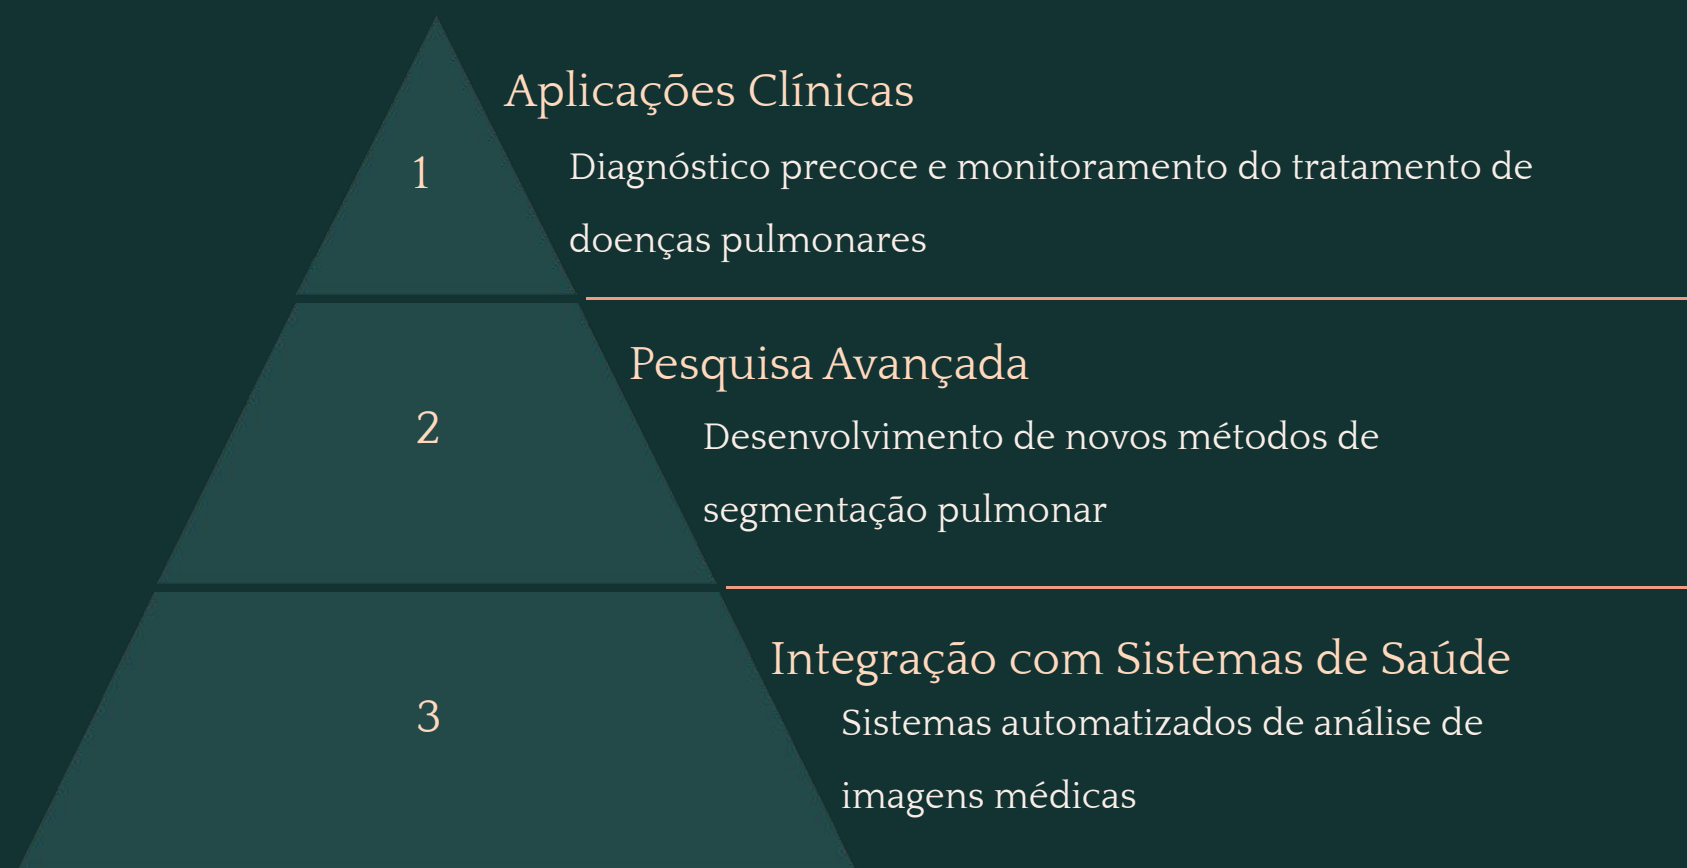
# Avaliação e Validação dos Modelos

- A avaliação e validação dos modelos de segmentação pulmonar são fundamentais para garantir sua eficácia e confiabilidade. Métricas como Dice Similarity, Precisão, Recall e Acurácia são comumente utilizadas para medir o desempenho dos algoritmos.
- Os modelos também devem ser validados em conjuntos de dados independentes, representativos da realidade clínica, para evitar o overfitting e garantir a generalização dos resultados.
- O overfitting se manifesta quando um algoritmo se adapta excessivamente ou até mesmo de forma precisa aos dados de treinamento, levando a um modelo que não consegue fazer previsões ou conclusões precisas com outros dados que não sejam os de treinamento.

Técnica	Descrição
Dice Similarity	Mede a sobreposição entre a segmentação automática e a segmentação manual (ground truth).
Precisão	Fração de pixels corretamente segmentados como pertencentes à região de interesse.
Acurácia	Fração de pixels corretamente classificados (tanto positivos quanto negativos).



# Conclusão e Perspectivas Futuras



Em conclusão, a aplicação de aprendizado de máquina para a segmentação de imagens pulmonares possui um imenso potencial, tanto para melhorar os cuidados clínicos quanto para impulsionar o avanço da pesquisa médica. À medida que a tecnologia evoluir, esperamos ver a integração desses métodos em sistemas de saúde, levando a diagnósticos mais precisos e tratamentos mais eficazes. As perspectivas futuras incluem a expansão das aplicações clínicas, o desenvolvimento de técnicas de segmentação ainda mais avançadas e a integração perfeita com os fluxos de trabalho dos profissionais de saúde.